



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Informe técnico grupal · 20 %

Título del proyecto: Análisis estadístico de condiciones meteorológicas en Australia
Integrantes: Enzo Pinilla, Claudio Alarcón y Luis Rodrigo Espinoza
Dataset: WeatherAUS (Rain in Australia)
Docente: Dr. Jean Paul Maidana González
Fecha: 30/06/2026
Repositorio GitHub: github.com/sauriomac/mcdi501-estadistica-computacional-grupo2

Información de la evaluación

Fase del proyecto: Fase 2: Búsqueda y recopilación de información

Modalidad: Grupal (3–4 integrantes) **Ponderación:** 20 % de la nota final

Entregables: Informe PDF (máx. 8 págs., sin anexos) · Notebook `.ipynb` · Repositorio GitHub

Resultado de aprendizaje (RA1): aplicar probabilidad e inferencia estadística en problemas de decisión bajo incertidumbre.

Indicadores: ID1.2, ID1.3, ID1.4.

Recuerden: los resultados de esta sumativa serán la entrada de S2 y S3.

Índice

1	Preparación y carga de datos	2
2	Análisis exploratorio de datos	2
3	Estimación de parámetros	5
4	Pruebas de hipótesis	6
4.1	Temperatura máxima según lluvia futura	6
4.2	Humedad a las 15:00 según lluvia futura	6
5	Informe de avance del proyecto	7
6	Notebook y repositorio GitHub	7
7	Bibliografía (APA 7)	7

1. Preparación y carga de datos

Se analizó el conjunto *WeatherAUS*, que contiene observaciones meteorológicas diarias de estaciones australianas y cuya variable objetivo, *RainTomorrow*, indica si al día siguiente se registró lluvia [1]. El problema consiste en identificar condiciones atmosféricas asociadas con lluvia futura para apoyar decisiones de monitoreo y definir variables prioritarias para etapas predictivas.

El archivo *weatherAUS.csv* se cargó con *pandas* [5]. La base original tiene 145.460 filas y 23 variables. Se fijó *SEED* = 42; se verificaron dimensiones, tipos, dominios, faltantes, duplicados y fechas inválidas. Como limpieza básica, *Date* se convirtió a fecha, se conservaron los faltantes sin imputar y se crearon codificaciones binarias auxiliares para las correlaciones. Los análisis usan casos completos por variable para evitar eliminar registros válidos de otras columnas.

Tabla 1: Reporte inicial de calidad de los datos.

Indicador	Cantidad	Resultado
Filas originales	145.460	Cargadas correctamente
Columnas originales	23	Tipos verificados
Duplicados exactos	0	Sin duplicados
Fechas inválidas	0	Sin inconsistencias
Variables con faltantes	21	Requieren tratamiento posterior
Controles de dominio evaluados	9	0 inconsistencias detectadas

Los controles de dominio confirmaron ausencia de precipitaciones y velocidades negativas, humedades fuera de 0–100, nubosidad fuera de 0–9, *MaxTemp* < *MinTemp* y categorías distintas de *Yes/No*. Las mayores tasas de ausencia corresponden a *Sunshine* (48,01 %), *Evaporation* (43,17 %), *Cloud3pm* (40,81 %) y *Cloud9am* (38,42 %). El mecanismo de ausencia no se presume aleatorio y se informa el tamaño muestral en cada procedimiento.

Tabla 2: Clasificación no redundante de las variables.

Tipo	Variables principales
Cuantitativas continuas	Temperaturas, precipitación, evaporación, horas de sol, velocidades del viento, humedades y presiones.
Ordinales discretas	<i>Cloud9am</i> y <i>Cloud3pm</i> , escalas ordenadas de cobertura nubosa.
Categorías nominales	<i>Location</i> , <i>WindGustDir</i> , <i>WindDir9am</i> y <i>WindDir3pm</i> .
Binarias	<i>RainToday</i> y <i>RainTomorrow</i> .
Temporal	<i>Date</i> .

2. Análisis exploratorio de datos

La Tabla 3 resume medidas de tendencia central, dispersión, posición y forma. La cuantificación de asimetría y curtosis responde directamente a la retroalimentación formativa [2].

Tabla 3: Estadística descriptiva de variables meteorológicas seleccionadas.

Variable	n	Media	DE	Mediana	Q1	Q3	Asim.	Curtosis
MinTemp	143.975	12,19	6,40	12,00	7,60	16,90	0,02	-0,48
MaxTemp	144.199	23,22	7,12	22,60	17,90	28,20	0,22	-0,22
Rainfall	142.199	2,36	8,48	0,00	0,00	0,80	9,84	178,15
Humidity9am	142.806	68,88	19,03	70,00	57,00	83,00	-0,48	-0,04
Humidity3pm	140.953	51,54	20,80	52,00	37,00	66,00	0,03	-0,51
Pressure9am	130.395	1.017,65	7,11	1.017,60	1.012,90	1.022,40	-0,10	0,23
Temp9am	143.693	16,99	6,49	16,70	12,30	21,60	0,09	-0,34
Temp3pm	141.851	21,68	6,94	21,10	16,60	26,40	0,24	-0,14
WindGustSpeed	135.197	40,04	13,61	39,00	31,00	48,00	0,87	1,42

MaxTemp es aproximadamente simétrica. En contraste, **Rainfall** presenta asimetría positiva extrema y curtosis elevada: la mayoría de los días registra precipitación nula o baja y pocos episodios concentran valores intensos. **WindGustSpeed** también posee asimetría positiva y colas pesadas, por lo que la mediana y los cuartiles complementan a la media.




Figura 1: Distribuciones de temperatura máxima y precipitación diaria.

Para las variables categóricas se calcularon frecuencias absolutas, porcentaje total y porcentaje entre casos válidos. **RainTomorrow** tiene 142.193 observaciones válidas: 110.316 “No” (77,58 %) y 31.877 “Yes” (22,42 %). La clase positiva es minoritaria. **Location** contiene 49 estaciones y las direcciones del viento poseen 16 categorías.




Figura 2: Frecuencia relativa de **RainTomorrow** y estaciones con mayor número de registros.

El análisis bivariado muestra que **Humidity3pm** tiene la mayor asociación lineal con **RainTomorrow** ($r = 0,446$), seguida de **RainToday** ($r = 0,313$), **Humidity9am** ($r = 0,257$), **Pressure9am** ($r = -0,246$), **Rainfall** ($r = 0,239$) y **WindGustSpeed** ($r = 0,234$). Entre predictores, **MaxTemp**

y **Temp3pm** alcanzan $r = 0,985$, lo que anticipa redundancia. Las correlaciones expresan asociaciones lineales, no causalidad.




Figura 3: Distribución de **MaxTemp** según la ocurrencia de lluvia al día siguiente.




Figura 4: Distribución de **Humidity3pm** según la ocurrencia de lluvia al día siguiente.




Figura 5: Matriz de correlación entre las variables meteorológicas seleccionadas.

3. Estimación de parámetros

Se estimaron las medias de MaxTemp, Humidity3pm y WindGustSpeed. Como las desviaciones poblacionales son desconocidas, se utilizó:

$$\bar{x} \pm t_{0,975;n-1} \frac{s}{\sqrt{n}}.$$

La proporción de lluvia futura se estimó mediante Wilson, en reemplazo de la aproximación normal simple sugerida en la evaluación formativa [3].

Tabla 4: Estimaciones puntuales e intervalos de confianza al 95 %.

Parámetro	n	Estimación	IC 95 %	Método
Media MaxTemp	144.199	23,221 °C	[23,185; 23,258]	t de Student
Media Humidity3pm	140.953	51,539 %	[51,431; 51,648]	t de Student
Media WindGustSpeed	135.197	40,035 km/h	[39,963; 40,108]	t de Student
Proporción RainTomorrow = Yes	142.193	22,418 %	[22,202; 22,636]	Wilson




Figura 6: Estimaciones puntuales e intervalos de confianza al 95 % para las medias seleccionadas.

El 95 % es una propiedad del procedimiento: al repetir el muestreo y la construcción bajo condiciones comparables, aproximadamente el 95 % de los intervalos contendría el parámetro verdadero. No corresponde asignar una probabilidad posterior de 95 % al parámetro dentro de este intervalo ya calculado.

La gran muestra produce intervalos estrechos, pero no elimina sesgos. Las observaciones provienen de estaciones y fechas repetidas, hay faltantes no modelados y la base no es una muestra aleatoria simple de todos los climas posibles. La generalización debe considerar heterogeneidad geográfica, estacional y temporal.

4. Pruebas de hipótesis

Se reemplazó el contraste arbitrario de **MaxTemp** contra 22 °C por dos preguntas vinculadas con la anticipación de lluvia. Se fijó $\alpha = 0,05$ para controlar el error tipo I. Se usó t de Welch, que compara medias de grupos independientes sin exigir varianzas iguales [6].

Los supuestos fueron: respuesta cuantitativa, grupos **Yes/No** mutuamente excluyentes y tamaños muestrales grandes, que permiten aplicar el Teorema Central del Límite. Welch evita suponer homocedasticidad. La independencia temporal y espacial puede ser imperfecta porque cada estación aporta mediciones repetidas; esta limitación deberá abordarse con modelos temporales o jerárquicos.

4.1 Temperatura máxima según lluvia futura

$$H_0 : \mu_{\text{Yes}} = \mu_{\text{No}} \quad \text{vs.} \quad H_1 : \mu_{\text{Yes}} \neq \mu_{\text{No}}.$$

La media fue 21,119 °C en días con lluvia futura ($n = 31.822$) y 23,836 °C en días sin lluvia ($n = 110.049$). La diferencia Yes–No fue $-2,717$ °C. Se obtuvo $t = -61,468$, $p < 0,001$ y $d = -0,387$; se rechaza H_0 . El efecto es pequeño: la temperatura aporta información, pero no distingue por sí sola ambos escenarios.

4.2 Humedad a las 15:00 según lluvia futura

$$H_0 : \mu_{\text{Yes}} = \mu_{\text{No}} \quad \text{vs.} \quad H_1 : \mu_{\text{Yes}} \neq \mu_{\text{No}}.$$

La humedad media fue 68,800 % con lluvia futura ($n = 30.913$) y 46,511 % sin lluvia ($n = 107.670$), diferencia de 22,289 puntos porcentuales. El resultado fue $t = 182,608$, $p < 0,001$ y $d = 1,198$; se rechaza H_0 . El efecto grande respalda priorizar **Humidity3pm** en el monitoreo y modelamiento, sin interpretarlo como causalidad.

Tabla 5: Resumen de pruebas t de Welch.

Variable	Dif. Yes-No	t	p	Cohen d	Decisión
MaxTemp	-2,717	-61,468	< 0,001	-0,387	Rechazar H_0
Humidity3pm	22,289	182,608	< 0,001	1,198	Rechazar H_0

5. Informe de avance del proyecto

La lluvia futura ocurre en 22,42 % de los casos válidos. **Rainfall** presenta fuerte asimetría y valores extremos, mientras que **Humidity3pm** es el hallazgo central: posee la mayor correlación con la variable objetivo y una diferencia entre grupos con tamaño del efecto grande. **MaxTemp** también difiere, pero con efecto pequeño, demostrando que significancia estadística no equivale a gran relevancia práctica.

Para una decisión preliminar conviene integrar humedad vespertina, lluvia actual, presión, precipitación y ráfagas, en vez de depender de una sola variable. Los próximos pasos son estudiar el mecanismo de faltantes; aplicar imputación sin fuga de información; revisar valores extremos; controlar variables redundantes; incorporar ubicación y estacionalidad; dividir los datos respetando el orden temporal; y evaluar modelos con precisión, exhaustividad, F1, ROC-AUC y PR-AUC.

6. Notebook y repositorio GitHub

El notebook `S1_Definicion.ipynb` sigue el mismo orden del informe, fija `SEED = 42`, ejecuta controles de calidad, genera las tablas y guarda las figuras en `results/figures`. La versión entregada fue verificada mediante **Kernel → Restart & Run All**, sin errores ni intervención manual. El repositorio enlazado en la portada separa datos crudos, notebooks, código, figuras y reportes, y documenta la ejecución en el README.

7. Bibliografía (APA 7)

Bibliografía

- [1] Kaggle. (2017). *Rain in Australia dataset*. <https://www.kaggle.com/datasets/jsphyg/weather-dataset-rattle-package>
- [2] Maidana, J. P. (2026). *Medidas de dispersión y forma: variabilidad, asimetría y curtosis* [Apunte de curso]. Universidad Andrés Bello.
- [3] Maidana, J. P. (2026). *Intervalos de confianza: cuantificando la incertidumbre estadística* [Apunte de curso]. Universidad Andrés Bello.
- [4] Maidana, J. P. (2026). *Pruebas de hipótesis: pruebas t y Z para una muestra* [Apunte de curso]. Universidad Andrés Bello.
- [5] McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt y J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56–61). <https://doi.org/10.25080/Majora-92bf1922-00a>
- [6] Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272. <https://doi.org/10.1038/s41592-019-0686-2>