



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL
MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 3

Modelamiento predictivo integrado

Predicción de lluvia del día siguiente en Australia

Integrantes	Enzo Pinilla · Claudio Alarcón · Luis Rodrigo Espinoza
Dataset	WeatherAUS / Rain in Australia (Kaggle, 2017)
Docente	Dr. Jean Paul Maidana González
Fecha	Julio de 2026
Repositorio	https://github.com/sauriomac/mcdi501-estadistica-computacional-grupo2
Notebook maestro	s3_modelamiento_final.ipynb

Conexión con evaluaciones anteriores

S1 identificó el desbalance de `RainTomorrow` (22,4 % de casos positivos), los faltantes altos en `Sunshine` y `Evaporation`, las colas pesadas de `Rainfall` y `WindGustSpeed`, y la casi colinealidad `MaxTemp-Temp3pm`. S2 validó mediante bootstrap y permutación las señales más estables, confirmó la cero-inflación de `Rainfall` y advirtió la dependencia por estación meteorológica. S3 convierte esos hallazgos en decisiones reproducibles: partición temporal, imputación aprendida solo en entrenamiento, `log1p(Rainfall)`, control VIF, ponderación de clase y métricas sensibles a la clase minoritaria.

Índice

1	Manejo inteligente de datos faltantes	3–4
2	Clasificación mediante regresión logística	4–8
3	Impacto de la estrategia de imputación	6
4	Síntesis integrada y conclusiones	6
5	Bibliografía	7

Reproducibilidad y ausencia de fuga

El notebook maestro se guardó después de *Restart Kernel and Run All Cells*, con las ocho celdas de código numeradas correlativamente y semilla fija 42. Todas las tablas y figuras del informe provienen de esa misma corrida. La imputación, el escalamiento, los límites de winsorización y la selección se aprenden exclusivamente con el entrenamiento temporal; el 30 % más reciente permanece fuera del ajuste. La implementación utiliza `scikit-learn` y `statsmodels` (Pedregosa et al., 2011; Seabold y Perktold, 2010).

Criterio de evaluación. La prueba final es temporal: se entrena con el pasado y se evalúa en observaciones cronológicamente posteriores. La validación agrupada por `Location` se mantiene como extensión espacial, no como sustituto de la prueba temporal.

1 Manejo inteligente de datos faltantes

1.1 Referencia a S1 y mecanismo de ausencia

S1 cuantificó los faltantes; S3 usa esos resultados como insumo en lugar de repetir el EDA. Las mayores tasas corresponden a **Sunshine** (48,01 %), **Evaporation** (43,17 %), **Cloud3pm** (40,81 %) y **Cloud9am** (38,42 %). La asociación entre ausencia y **Location** es fuerte: los V de Cramér fluctúan entre 0,776 y 0,909, con $p < 0,001$. Por ello se adopta MAR como supuesto de trabajo, sin afirmar que MNAR haya sido descartado (Little y Rubin, 2019).

Cuadro 1: Principales faltantes y evidencia del mecanismo de ausencia.

Variable	Faltantes	%	V de Cramér con Location
Sunshine	69.835	48,01	0,859
Evaporation	62.790	43,17	0,858
Cloud3pm	59.358	40,81	0,776
Cloud9am	55.888	38,42	0,814
Pressure9am	15.065	10,36	0,908
WindGustSpeed	10.263	7,06	0,782

1.2 Imputación mediante regresión lineal múltiple

Para cada variable numérica incompleta se eligieron entre tres y cinco predictores a partir de la matriz de correlaciones de S1, priorizando secundariamente señales estables de S2. Cada regresión se ajustó con casos completos del período de entrenamiento y se aplicó después a entrenamiento y prueba. **RainToday** se imputó por moda, por ser binaria. Las predicciones se acotaron a dominios físicamente plausibles.

Cuadro 2: Ejemplos de modelos de imputación y validación temporal.

Variable	Imp. entren.	Imp. prueba	R^2 val.	Predictores principales
Sunshine	37.576	30.240	0,691	Cloud3pm, Cloud9am, humedades y Temp3pm
Evaporation	34.291	26.552	0,445	MaxTemp, Temp3pm, Temp9am, Humidity9am y MinTemp
Pressure9am	8.607	5.407	0,938	Pressure3pm, WindGustSpeed, MinTemp, Temp9am y MaxTemp
WindGustSpeed	6.490	2.780	0,628	velocidades de viento, presiones y Humidity9am
Rainfall	924	482	0,260	RainToday, humedades, Sunshine y Cloud9am

Los modelos de temperatura y presión alcanzan ajustes altos; **Rainfall** es más difícil por su cero-inflación y cola extrema. La imputación determinista por regresión puede encoger la varianza; por ello se compara con eliminación e imputación simple y se propone imputación múltiple como mejora futura.

1.3 Comparación de estrategias y partición

Se compararon eliminación, imputación simple e imputación mediante regresión lineal múltiple. La regresión preservó mejor que la mediana la correlación de **Sunshine** con el objetivo ($-0,397$ frente a $-0,324$), y mantuvo relaciones próximas a las observadas para **Humidity3pm**, **Pressure9am** y **Rainfall_log1p**. La decisión final se basa también en el desempeño del mismo modelo, no solo en distribuciones marginales.




Figura 1: Distribuciones observadas e imputadas y residuos frente a valores ajustados para variables de alta ausencia.

2 Clasificación mediante regresión logística

2.1 Preparación informada por S1 y S2

Se ordenaron las fechas y se reservó el 30 % más reciente como prueba: 93.076 registros hasta el 29-08-2014 para entrenamiento y 49.117 registros posteriores para prueba. Las tasas positivas son 22,81 % y 21,67 %, respectivamente. Esta partición evita utilizar información futura para estimar desempeño.

- **Rainfall** se transforma mediante $\log(1 + x)$; **WindGustSpeed** se winsoriza en percentiles 1–99 aprendidos en entrenamiento.
- Los predictores se estandarizan con parámetros del entrenamiento y la ponderación de clase se reserva para la predicción.
- La inferencia de coeficientes y razones de momios se realiza con Logit no ponderado, para comparar homogéneamente Wald y bootstrap.
- El control preliminar elimina **Pressure3pm** ($VIF = 19,01$) y evita usar simultáneamente **MaxTemp** y **Temp3pm**.

2.2 Selección de variables informada por S1 y S2

Se ejecutaron por separado los modelos exigidos: M1 guiado por S1/S2, M2 con eliminación stepwise y M3 basado en BIC. Se añadió M4 como contraste reducido de parsimonia. La validación interna usa particiones temporales consecutivas, no folds aleatorios (James et al., 2013; Maidana, 2026).

- **M1 Dominio (5)**: **Humidity3pm**, **RainToday**, **Pressure9am**, **Rainfall_log1p** y **WindGustSpeed**.
- **M2 Stepwise (13)**: elimina **RainToday** por falta de aporte condicional y conserva variables meteorológicas y estacionales.
- **M3 BIC (14)**: retiene las 13 de M2 más **RainToday**; su desempeño es prácticamente idéntico.
- **M4 Reducido (8)**: sirve como contraste parsimonioso, pero pierde discriminación en la prueba temporal.

Cuadro 3: Modelos y desempeño en prueba temporal (umbral 0,5; clases ponderadas).

Modelo	Vars.	Accuracy	Precision	Recall	F1	AUC
M1 Dominio S1/S2	5	0,777	0,490	0,721	0,583	0,834
M2 Stepwise	13	0,785	0,502	0,743	0,599	0,852
M3 BIC	14	0,785	0,502	0,743	0,599	0,852
M4 Reducido	8	0,770	0,480	0,723	0,577	0,832

M2 obtiene AUC temporal interno $0,86498 \pm 0,00442$ y M3 $0,86497 \pm 0,00443$. Como la diferencia es despreciable y M2 utiliza una variable menos, se adopta **M2 Stepwise** como modelo final. El conjunto de prueba no intervino en esta decisión.




Figura 2: Curvas ROC de las cuatro especificaciones en la prueba temporal.

2.3 Coeficientes y lectura contextual

Los predictores estandarizados permiten interpretar cada OR por una desviación estándar. **Humidity3pm** es la señal principal ($OR = 2,93$), seguida de **WindGustSpeed** ($OR = 2,00$) y **Temp3pm** ($OR = 1,59$). **Sunshine** ($OR = 0,63$) y **Pressure9am** ($OR = 0,71$) actúan como factores protectores. Estas asociaciones no se interpretan como causalidad (Hosmer et al., 2013).

2.4 Estabilidad mediante bootstrap

Siguiendo el enfoque de S2, se aplicaron 500 remuestras bootstrap de tamaño completo al Logit no ponderado. Cada remuestra reajusta los 13 coeficientes por máxima verosimilitud; el número es menor que las 10.000 remuestras de S2 debido al costo de reajustar un modelo completo. Se construyeron intervalos percentiles al 95 % y se compararon con Wald (Efron y Tibshirani, 1993).

Cuadro 4: Coeficientes y OR del modelo final con IC bootstrap percentil al 95 %.

Variable	Coeficiente [IC95]	OR [IC95]	Estable
Humidity3pm	1,075 [1,045; 1,108]	2,929 [2,842; 3,029]	Sí
WindGustSpeed	0,694 [0,665; 0,725]	2,002 [1,945; 2,065]	Sí
Sunshine	-0,461 [-0,497; -0,428]	0,631 [0,608; 0,652]	Sí
Pressure9am	-0,348 [-0,370; -0,326]	0,706 [0,691; 0,722]	Sí
Rainfall_log1p	0,241 [0,223; 0,261]	1,273 [1,250; 1,298]	Sí
Temp3pm	0,464 [0,433; 0,496]	1,591 [1,541; 1,641]	Sí
Cloud3pm	0,284 [0,251; 0,317]	1,328 [1,286; 1,374]	Sí
Humidity9am	0,095 [0,063; 0,129]	1,100 [1,065; 1,138]	Sí




Figura 3: Razones de momios e intervalos bootstrap. Ningún intervalo cruza OR=1.

Ningún parámetro del modelo final resulta inestable. La cercanía entre los intervalos bootstrap y Wald es plausible con más de 93 mil observaciones, pero el remuestreo aporta una comprobación empírica y conecta directamente S2 con S3.

2.5 Diagnóstico de supuestos

Multicolinealidad. El VIF máximo es 3,95 (*Sunshine*); todos quedan bajo el umbral de 5. El control previo resolvió la redundancia de presiones y temperaturas.

Linealidad en el logit. El diagnóstico tipo Box–Tidwell encuentra posible no linealidad en nueve predictores, relacionados con humedad, lluvia transformada, horas de sol, evaporación, nubosidad, temperatura, viento vespertino y el ciclo estacional. Esto no invalida la utilidad predictiva, pero limita la lectura lineal de los coeficientes y motiva splines o transformaciones futuras (Hosmer et al., 2013).

Residuos e influencia. En una muestra reproducible de 25.000 observaciones, 2,044 % presenta $|r_{Pearson}| > 3$. La distancia de Cook máxima es 0,0028 y el leverage máximo 0,0254; no aparece una sola observación que domine el ajuste. El umbral $4/n$ se interpreta con cautela porque se vuelve muy pequeño en muestras grandes.




Figura 4: VIF del modelo final y diagnóstico de residuos e influencia.

Lectura crítica. El modelo es estable y no presenta multicolinealidad severa, pero varias relaciones no son estrictamente lineales en el logit. Por ello se presenta como línea base interpretable, no como forma funcional definitiva.

2.6 Evaluación de desempeño predictivo

El AUC del modelo final es 0,867 en entrenamiento y 0,852 en prueba temporal. La caída es moderada y esperable por el cambio de período; no se observa sobreajuste severo. En prueba se obtienen 30.629 verdaderos negativos, 7.842 falsos positivos, 2.734 falsos negativos y 7.912 verdaderos positivos.

Cuadro 5: Desempeño del modelo final en entrenamiento y prueba.							
Partición	Accuracy	Precision	Recall	Espec.	F1	ROC-AUC	PR-AUC
Entrenamiento	0,790	0,526	0,772	0,795	0,626	0,867	0,696
Prueba temporal	0,785	0,502	0,743	0,796	0,599	0,852	0,655




Figura 5: ROC de las cuatro especificaciones y matrices del modelo final en entrenamiento y prueba temporal.

La ponderación de clase recupera 74,3% de los días con lluvia. La precisión de 50,2% refleja el costo de esa sensibilidad: aproximadamente la mitad de las alertas positivas son falsas. El umbral 0,5 es un punto operativo inicial y debe calibrarse según el costo relativo de no anticipar lluvia frente a emitir una alerta innecesaria. El PR-AUC complementa al ROC-AUC al concentrarse en la clase minoritaria.

3 Análisis comparativo del impacto de la imputación

Cuadro 6: Modelo final ajustado con las tres estrategias de tratamiento de faltantes.							
Estrategia	n prueba	Accuracy	Precision	Recall	F1	AUC	PR-AUC
Eliminación	15.195	0,805	0,527	0,742	0,616	0,871	0,681
Imputación simple	49.117	0,794	0,518	0,714	0,601	0,850	0,653
Imputación por regresión	49.117	0,785	0,502	0,743	0,599	0,852	0,655

La eliminación parece alcanzar mayor AUC, pero reduce la prueba de 49.117 a 15.195 casos y selecciona estaciones o períodos con instrumentos completos. Evalúa una población distinta, por lo que no demuestra superioridad general. Entre las estrategias comparables de igual tamaño, la imputación por regresión conserva todos los casos y alcanza el mayor recall y PR-AUC. Se adopta como estrategia principal, reconociendo el posible encogimiento de varianza.



Figura 6: Impacto de la imputación en métricas y coeficientes del modelo final.

4 Síntesis integrada y conclusiones

Resumen ejecutivo. El proyecto entrega un modelo temporalmente evaluado con ROC-AUC 0,852, PR-AUC 0,655 y recall 0,743. La lluvia del día siguiente se asocia principalmente con humedad vespertina, ráfagas, temperatura, nubosidad y lluvia reciente; mayor presión y horas de sol reducen las odds. Los coeficientes son estables bajo 500 remuestras y no presentan VIF problemático.

Discusión y recomendaciones. La principal limitación es la no linealidad de varios predictores en el logit. Se recomienda calibrar el umbral según costos, complementar la prueba temporal con validación agrupada por Location, explorar splines e imputación múltiple, y monitorear calibración y estabilidad en nuevos años. El modelo debe apoyar, no sustituir, decisiones meteorológicas u operativas.

5 Bibliografía

- Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.
- Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3.^a ed.). Wiley.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An introduction to statistical learning*. Springer.
- Kaggle. (2017). *Rain in Australia* [Conjunto de datos]. <https://www.kaggle.com/datasets/jsphyg/weather-dataset-rattle-package>.
- Little, R. J. A., & Rubin, D. B. (2019). *Statistical analysis with missing data* (3.^a ed.). Wiley.
- Maidana, J. P. (2026). *Selección de variables y comparación de modelos* [Apunte del curso MCDI501]. Universidad Andrés Bello.
- Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. *Proceedings of the 9th Python in Science Conference*, 92–96.

Todas las cifras y figuras de este informe provienen de una única ejecución del notebook maestro.