



MCDI501 · Sumativa 3 · Grupo 2

## **Evaluación Sumativa 3**

Modelamiento predictivo integrado

Predicción de lluvia del día siguiente en Australia

Enzo Pinilla · Claudio Alarcón · Luis Rodrigo Espinoza

Dr. Jean Paul Maidana González · Julio 2026

### Idea central

El proyecto convierte hallazgos estadísticos previos en decisiones de modelamiento reproducibles.

S1

**¿Qué hay en los datos?**

Faltantes, desbalance, outliers y correlaciones.

S2

**¿Qué resultados son estables?**

Bootstrap, permutación, Monte Carlo y robustez.

S3

**¿Qué modelo funciona fuera de muestra?**

Imputación, selección, diagnóstico y prueba temporal.

### Principio rector

Ninguna decisión de S3 se toma desde cero: cada transformación y variable se rastrea a evidencia previa.

# S1: señales y problemas que condicionan el modelo

El análisis exploratorio se convierte en decisiones técnicas

Clase positiva

**22,4 %**

RainTomorrow = Yes

Faltantes

**48,0 %**

Sunshine; Evaporation 43,2 %

Colinealidad

$r \approx 0,985$

MaxTemp–Temp3pm

Rainfall

**Cero-inflada**

Cola derecha extrema

## Señales relevantes

- ▶ Humidity3pm: asociación positiva más fuerte.
- ▶ RainToday y Rainfall: persistencia de precipitación.
- ▶ Pressure9am: asociación protectora.
- ▶ WindGustSpeed: señal útil, sensible a extremos.

## Consecuencias para S3

- ▶ Imputar en vez de borrar casos completos.
- ▶ No usar MaxTemp y Temp3pm simultáneamente.
- ▶ Aplicar log1p a Rainfall.
- ▶ Usar métricas sensibles a la clase minoritaria.

## S2: validación y retroalimentación

La evidencia validada define la arquitectura del modelo final

### Validado en S2

- ▶ Correlaciones estables: Humidity3pm, RainToday, Humidity9am, Pressure9am y Rainfall.
- ▶ Permutación con estadístico studentizado y  $p < 0,001$ .
- ▶ Bootstrap coherente con intervalos clásicos.
- ▶ Rainfall requiere lectura robusta y  $\log_{10}$ .

### Retroalimentación incorporada

- ▶ Notebook ejecutable de principio a fin.
- ▶ Cada cifra sale de la misma corrida.
- ▶ Ponderación de clase y métricas minoritarias.
- ▶ Partición temporal o agrupada por Location.

#### Entrenamiento

**93.076**

Hasta 29-08-2014

#### Prueba temporal

**49.117**

Posterior al corte

#### Semilla

**42**

Reproducibilidad

## S3: reproducibilidad y ausencia de fuga

Preparación aprendida solo desde el entrenamiento temporal

### Flujo reproducible

- 1 Cargar datos y excluir RISK\_MM.
- 2 Ordenar por fecha.
- 3 Separar 70 % entrenamiento y 30 % prueba.
- 4 Aprender imputación, escalamiento y selección.
- 5 Evaluar en prueba temporal intacta.

### Qué se aprende solo con entrenamiento

- ▶ Modelos de imputación.
- ▶ Medianas y modas.
- ▶ Parámetros de estandarización.
- ▶ Límites de winsorización.
- ▶ Selección de variables.

### Resultado

El desempeño reportado se mide sobre datos cronológicamente posteriores, no sobre una mezcla aleatoria.

# Manejo de faltantes sin fuga de información

Regresiones lineales múltiples aprendidas solo en entrenamiento

Sunshine

$$R^2 = 0,691$$

67.816 imputados

Evaporation

$$R^2 = 0,445$$

60.843 imputados

Pressure9am

$$R^2 = 0,938$$

14.014 imputados

Rainfall

$$R^2 = 0,260$$


Cero-inflación

## Estrategias comparadas

- ▶ Eliminación de casos completos.
- ▶ Mediana / moda.
- ▶ Regresión lineal múltiple seleccionada.

## Supuesto declarado

MAR es plausible por relación entre faltantes y Location; MNAR no se descarta.



Diagnóstico de imputación generado por el notebook S3.

# Modelos solicitados y selección trazable

Stepwise y BIC se ejecutan por separado; el final se elige con CV temporal

| Modelo           | Variables | AUC test | Recall | Decisión                                                      |
|------------------|-----------|----------|--------|---------------------------------------------------------------|
| M1 Dominio S1/S2 | 5         | 0,834    | 0,721  | Base con evidencia previa                                     |
| M2 Stepwise      | 13        | 0,852    | 0,743  | Modelo final                                                  |
| M3 BIC           | 14        | 0,852    | 0,743  | Mismo rendimiento, menos parsimonia<br>Contraste parsimonioso |
| M4 Reducido      | 8         | 0,832    | 0,723  |                                                               |

## Supuesto declarado

M2 Stepwise:  $CV\text{-}AUC = 0,86498 \pm 0,00442$ . M3 rinde igual, pero usa una variable más; M2 queda por parsimonia.

# Desempeño en prueba temporal

Buena discriminación y 74 % de recuperación de días lluviosos

ROC-AUC

**0,852**

Bueno

PR-AUC

**0,655**

Clase positiva

Recall

**0,743**

7.912 VP

Precision

**0,502**

7.842 FP

F1

**0,599**


Equilibrio

Accuracy

**0,785**

Test temporal

|         | Pred. No | Pred. Sí |
|---------|----------|----------|
| Real No | 30.629   | 7.842    |
| Real Sí | 2.734    | 7.912    |



Curvas ROC.

## Interpretación operativa

La ponderación recupera 74,3 % de los días lluviosos. El costo es emitir más falsas alarmas; el umbral debe calibrarse según contexto.



# Estabilidad de coeficientes

Bootstrap conecta la validación de S2 con el modelo de S3

Bootstrap

**B = 500**

Reajustes completos

Inestables

**0**

Ningún IC cruza OR=1


Train

**93.076**

Logit no ponderado

## Principales odds ratios

- ▶ Humidity3pm: OR 2,93.
- ▶ WindGustSpeed: OR 2,00.
- ▶ Temp3pm: OR 1,59.
- ▶ Sunshine: OR 0,63.
- ▶ Pressure9am: OR 0,71.



Intervalos bootstrap de los OR del modelo final.

# Diagnóstico: estable, pero no definitivo

## Métricas separadas y gráficos de diagnóstico del modelo

VIF máximo

**3,95**

Menor que 5

Pearson > 3

**2,04 %**

Muestra 25 mil

Cook máx.

**0,0028**

Sin dominancia


Leverage máx.

**0,0254**

Controlado

## Lectura

No hay multicolinealidad severa;  
Box–Tidwell sugiere no linealidad en varias  
señales meteorológicas.



VIF, residuos e influencia.



# Impacto de la imputación

La eliminación parece atractiva, pero cambia la población evaluada

| Estrategia  | <i>n</i> prueba | Recall | AUC   | PR-AUC |
|-------------|-----------------|--------|-------|--------|
| Eliminación | 15.195          | 0,742  | 0,871 | 0,681  |
| Simple      | 49.117          | 0,714  | 0,850 | 0,653  |
| Regresión   | 49.117          | 0,743  | 0,852 | 0,655  |

## Lectura crítica

La eliminación alcanza mayor AUC, pero reduce la prueba y selecciona estaciones o períodos completos.



Impacto de imputación en métricas y coeficientes.

# Conclusiones y recomendaciones

S1 descubrió. S2 validó. S3 integró y evaluó.

## Conclusión principal

Modelo temporalmente evaluado con AUC 0,852, PR-AUC 0,655 y recall 0,743. Los coeficientes son estables y no hay VIF problemático.

## Uso recomendado

Apoyar decisiones operativas, no sustituir sistemas meteorológicos especializados. El umbral debe calibrarse según costos reales.

## Mejoras futuras

- ▶ Calibrar umbral según costos operativos.
- ▶ Validar también por Location.
- ▶ Usar splines para no linealidad.
- ▶ Evaluar imputación múltiple.
- ▶ Monitorear calibración y estabilidad.



# Gracias

Predicción de lluvia del día siguiente en Australia

MCDI501 · Sumativa 3 · Grupo 2